Laboratorio 9 — Task 4

Curso: Deep Learning 10

Autores: Diego Lopez, Ricardo Godinez, Vianka Castro y Felipe Aguilar

Comparación de VAE y difusión; estimación de pass@k

4.1(a) — Nitidez

Se mide la media de |x[i,j+1] − x[i,j]| sobre 500 imágenes de cada grupo, con todos los píxeles en [0,1]. Las reales son las primeras 500 de validación. Las de difusión son exactamente las 500 de la Task 3.4 con w=1, guardadas en uint8 y divididas entre 255. La cuantización puede cambiar la métrica como máximo en 1/255 respecto al tensor flotante original.

El repositorio no incluía los pesos del VAE. Se repitió solo β=1 con la arquitectura de la Task 1 (784→400→2→400→784), semilla 3045, 20 épocas, Adam, lr=0.001 y lotes de 128. Se conservaron las primeras 55 000 imágenes para entrenamiento y las últimas 5 000 para validación. Las muestras proceden de z ~ N(0,I). Es una nueva ejecución, no los pesos originales.

Grupo	Imágenes	Nitidez
Reales	500	0.088579
VAE β=1	500	0.044968
Difusión w=1	500	0.089737



Figura 1. Muestras reales, VAE y difusión, con idéntica escala de visualización. La fila de difusión muestra una imagen de cada clase. No son pares de reconstrucción.

4.1(b) — Velocidad de generación

Equipo: macOS-26.6.2-arm64-arm-64bit. PyTorch 2.13.0; CPU, float32, 4 hilos. Ambos modelos se midieron en el mismo equipo, con lotes de 100 y sin gradientes. Se reporta la mediana de tres repeticiones después de calentar las redes. Se incluye el sorteo del ruido y el muestreo; se excluyen entrenamiento, carga, gráficos y escritura.

Modelo	Mediana, 100 imágenes	Evaluaciones por lote
VAE	0.000291 s	1
Difusión	56.237384 s	1000

VAE, repeticiones (s): 0.000261, 0.000319, 0.000291

Difusión, repeticiones (s): 56.237384, 56.175745, 56.362619

Razón t(difusión)/t(VAE) = 193006.9. Sin guía significa w=1: predicción condicional pura, sin una segunda evaluación incondicional. El decoder requiere una evaluación por imagen y la U-Net 1000; al procesar las 100 juntas son 1 y 1000 llamadas por lote.

4.1(c) — Nitidez, velocidad y estabilidad

El VAE obtuvo nitidez **0.044968**, frente a **0.089737** de difusión y **0.088579** de las imágenes reales. La difusión conserva más variación local; esta métrica también puede aumentar por ruido y no demuestra por sí sola calidad semántica. En la figura, el VAE suaviza contornos y texturas, mientras la difusión conserva más detalle. El VAE tarda **0.000291 s** por 100 imágenes y la difusión **56.237 s**: **193006.9 veces** más tiempo, con 1 frente a 1000 evaluaciones por lote.

El VAE prioriza velocidad a costa de nitidez: comprime a dos dimensiones y su reconstrucción cuadrática favorece promedios. Su pérdida de validación pasó de **33.2291** a **28.3794**. En la Task 3 la pérdida de difusión pasó de **0.1250** a **0.0408** en 30 épocas. Ambas corridas convergieron sin un entrenamiento adversarial, pero sus pérdidas tienen escalas distintas y una sola semilla no prueba estabilidad general.

Para acelerar difusión implementaría un muestreador de pasos reducidos, por ejemplo DDIM con 50 pasos, y volvería a medir nitidez y fidelidad. Eso reduciría las evaluaciones teóricas de 1000 a 50; no basta con truncar los últimos pasos del muestreador ancestral ni implica una aceleración medida de 20 veces.

Referencia para la propuesta de aceleración: Song, Meng y Ermon (2021), Denoising Diffusion Implicit Models, ICLR. No se implementó ni cronometró DDIM.

4.2 — Muestreo de soluciones y pass@k

(a) Estimador insesgado

Para n=20 y c éxitos: pass@k = 1 − C(n−c,k)/C(n,k). El cociente es la probabilidad de elegir solo fallos sin reemplazo. Se calculó en PyTorch float64 con el producto de (n−c−i)/(n−i).

Problema	c	pass@1	pass@5	pass@10	Ingenuo@5
P1	0	0.000000	0.000000	0.000000	0.000000
P2	2	0.100000	0.447368	0.763158	0.409510
P3	5	0.250000	0.806308	0.983746	0.762695
P4	9	0.450000	0.970201	0.999940	0.949672
P5	14	0.700000	0.999613	1.000000	0.997570
P6	20	1.000000	1.000000	1.000000	1.000000
Promedio	—	0.416667	0.703915	0.791141	0.686574

P2 con k=5: C(18,5)=8568 y C(20,5)=15504. Entonces pass@5 = 1 − 8568/15504 = 17/38 = 0.4473684211.

(b) Menor k para P2

Al cancelar factoriales, C(18,k)/C(20,k) = 18!(20−k)! / [20!(18−k)!] = (20−k)(19−k)/380, para 1≤k≤18. Así, pass@k = 1 − (20−k)(19−k)/380. Para k=19,20 también vale: no existen suficientes fallos y el producto es cero. Exigir pass@k > 0.9 equivale a (20−k)(19−k) < 38. Para k=13: 42 y pass@13=0.889474; para k=14: 30 y pass@14=0.921053. Por monotonía, el mínimo es 14.

(c) Por qué la versión ingenua no excede a la insesgada

Si n−c≥k, los factores son no negativos y (n−c−i)/(n−i) = 1−c/(n−i) ≤ 1−c/n. Al multiplicar y restar de 1, 1−∏[(n−c−i)/(n−i)] ≥ 1−(1−c/n)^k. Si n−c<k, el estimador insesgado vale 1 y la desigualdad se mantiene. P2: 0.447368 frente a 0.409510; P3: 0.806308 frente a 0.762695. La versión ingenua supone intentos independientes con reemplazo y trata c/n como exacto.

(d) Agente que reintenta hasta diez veces

En el conjunto finito, P1 no se resuelve (0); P2 tiene probabilidad 0.763158, P3 0.983746 y P4 0.999940. P5 y P6 tienen probabilidad 1 porque hay menos de diez fallos. No es correcto garantizar P2–P4. El verificador reconoce éxitos, pero no los genera; estas garantías no se trasladan a diez nuevas generaciones independientes ni a reintentos correlacionados con retroalimentación.

El promedio aumenta de **0.416667** en pass@1 a **0.791141** en pass@10 (**37.45 puntos porcentuales**). El modelo produce soluciones útiles que no siempre aparecen al primer intento; muestrear y verificar ayuda, pero no corrige P1, donde no se observó ningún éxito.